SMART CLASSROOM SURVEILLANCE USING POSE ESTIMATION

Le Hung Linh[1], Tran Van Hung[2], Duong Duc Tuong[1],
Vu Tien Khai[1], Nguyen Ngoc Khoa[3], Ngo Huu Huy[1*]
[1]TNU - University of Information and Communication Technology
[2]Thai Nguyen High School for the Gifted, [3]TNU - University of Education

ARTICLE INFO

Received: 19/7/2025
Revised: 03/10/2025
Published: 04/10/2025

KEYWORDS

Classroom monitoring
Faster R-CNN
HRNet
Student behavior recognition
YOLOv8-Pose

ABSTRACT

The Fourth Industrial Revolution has had a tremendous impact on the digital transformation of education, since it has actively encouraged the integration of modern technology into the learning environment. In particular, the use of computer vision and deep learning has emerged as a promising solution for automatically monitoring and analyzing student behavior in class. This study provides two new frameworks based on posture matching points for identifying prevalent student actions in the classroom. The first pipeline uses YOLOv8-Pose, a real-time model that tightly integrates object identification and pose estimation. The second pipeline combines Faster R-CNN with HRNet to create a high-precision system. The matching points obtained from both streams are then sent into the Convolutional Neural Network, which appropriately classifies student behavior. Comprehensive experimental results reveal that the HRNet-based framework achieves exceptional accuracy, making it appropriate for scenarios requiring high accuracy, whilst YOLOv8-Pose provides advantages in processing speed and real-time deployment.

GIÁM SÁT LỚP HỌC THÔNG MINH BẰNG NHẬN DIỆN TƯ THẾ

Lê Hùng Linh[1], Trần Văn Hưng[2], Dương Đức Tưởng[1],
Vũ Tiến Khải[1], Nguyễn Ngọc Khoa[3], Ngô Hữu Huy[1*]
[1]Trường Đại học Công nghệ Thông tin và Truyền thông - ĐH Thái Nguyên
[2]Trường THPT Chuyên Thái Nguyên, [3]Trường Đại học Sư phạm - ĐH Thái Nguyên

THÔNG TIN BÀI BÁO

Ngày nhận bài: 19/7/2025
Ngày hoàn thiện: 03/10/2025
Ngày đăng: 04/10/2025

TỪ KHÓA

Giám sát lớp học
Faster R-CNN
HRNet
Nhận dạng hành vi học sinh
YOLOv8-Pose

TÓM TẮT

Cuộc Cách mạng công nghiệp lần thứ tư đã có tác động to lớn đến quá trình chuyển đổi số trong giáo dục, bởi nó đã thúc đẩy mạnh mẽ việc tích hợp công nghệ hiện đại vào môi trường học tập. Đặc biệt, việc ứng dụng thị giác máy tính và học sâu đã trở thành giải pháp tiềm năng cho việc giám sát và phân tích hành vi học sinh một cách tự động trong lớp học. Nghiên cứu này giới thiệu hai khung phương pháp mới dựa trên điểm khớp tư thế để nhận diện các hành vi phổ biến của học sinh trong lớp học. Quy trình xử lý thứ nhất sử dụng YOLOv8-Pose, một mô hình thời gian thực tích hợp chặt chẽ nhận dạng đối tượng và ước tính tư thế. Quy trình xử lý thứ hai kết hợp Faster R-CNN với HRNet để tạo ra một hệ thống có độ chính xác cao. Các điểm khớp thu được từ cả hai luồng sau đó được đưa vào mạng nơ-ron tích chập, nơi phân loại hành vi của học sinh một cách chính xác. Các kết quả thử nghiệm toàn diện cho thấy nền tảng dựa trên HRNet đạt được độ chính xác vượt trội, phù hợp với các tình huống yêu cầu độ chính xác cao, trong khi YOLOv8-Pose mang lại lợi thế về tốc độ xử lý và triển khai thời gian thực.

DOI: https://doi.org/10.34238/tnu-jst.13256

* Corresponding author. *Email: nhhuy@ictu.edu.vn*

1. Giới thiệu

Trong bối cảnh Cách mạng công nghiệp 4.0 đang diễn ra mạnh mẽ trên toàn cầu, hầu hết các lĩnh vực trong đời sống xã hội đều chứng kiến những thay đổi mang tính đột phá – và giáo dục không phải là ngoại lệ. Sự phát triển nhanh chóng của công nghệ thông tin, trí tuệ nhân tạo (AI) và Internet vạn vật (IoT) đã thúc đẩy quá trình chuyển đổi số trong giáo dục diễn ra sâu rộng, đặc biệt trong hoạt động giảng dạy và quản lý lớp học. Thay vì phụ thuộc hoàn toàn vào mô hình lớp học truyền thống với phương pháp truyền đạt một chiều, các công cụ công nghệ hiện đại đã được tích hợp nhằm cá nhân hóa quá trình học tập, nâng cao chất lượng giảng dạy và giảm tải khối lượng công việc cho giáo viên.

Trong môi trường lớp học hiện đại, nơi giáo viên phải quản lý cùng lúc nhiều học sinh với sự đa dạng về tâm lý, hành vi và năng lực, việc quan sát thủ công để nắm bắt trạng thái học tập của từng em là một thách thức lớn. Điều này dễ dẫn đến bỏ sót các biểu hiện mất tập trung hoặc hành vi tiêu cực, ảnh hưởng đến hiệu quả giảng dạy. Do đó, hệ thống giám sát hành vi học sinh dựa trên thị giác máy tính và học sâu đang dần trở thành công cụ hữu hiệu, cho phép nhận diện các hành vi như giơ tay phát biểu, cúi mặt, nhìn ra ngoài, ngủ gật hoặc không chú ý trong thời gian thực. Những thông tin này giúp giáo viên điều chỉnh phương pháp giảng dạy phù hợp với từng cá nhân hoặc nhóm học sinh, hướng tới một môi trường học tập thông minh và thích ứng.

Song song với nhu cầu đó, các tiến bộ vượt bậc trong thị giác máy tính và học sâu trong hơn một thập kỷ qua đã mở ra nhiều cơ hội mới cho bài toán nhận diện hành vi. Các mô hình học sâu hiện đại như mạng nơ-ron tích chập (CNN), Transformer, và các kiến trúc chuyên biệt như Faster R-CNN, HRNet, OpenPose, hay L2CS-Net đã đạt độ chính xác cao trong các nhiệm vụ như phát hiện người, trích xuất các điểm khớp (keypoints) cơ thể, ước lượng ánh nhìn và nhận diện hành vi phức tạp trong môi trường đông người như lớp học [1] - [3]. Trong đó, CNN là nền tảng cho nhiều ứng dụng thị giác máy tính nhờ khả năng học đặc trưng mạnh mẽ, với các biến thể như ResNet, DenseNet và MobileNet giúp tối ưu hóa hiệu suất và tài nguyên [4] - [6]. Các mô hình Transformer như Vision Transformer (ViT) và Swin Transformer mở rộng khả năng học các mối quan hệ không gian rộng. HRNet nổi bật với khả năng giữ nguyên độ phân giải trong suốt quá trình trích xuất các điểm khớp, còn OpenPose và L2CS-Net lần lượt phù hợp cho nhận diện tư thế theo thời gian thực và ước lượng hướng nhìn – một yếu tố quan trọng để đánh giá sự chú ý của học sinh.

Bên cạnh sự phát triển của các mô hình thị giác máy tính, nhiều nghiên cứu gần đây đã đề xuất các kiến trúc chuyên biệt nhằm nâng cao hiệu quả nhận diện hành vi học sinh trong lớp học. Jia và cộng sự [7] đã xây dựng mô hình Student Behavior Detection (SBD), kết hợp giữa YOLOv5, cơ chế Contextual Attention (CA) và OpenPose, trong đó họ cải tiến bằng cách tích hợp CA và thay thế VGG-19 trong OpenPose, giúp cải thiện độ chính xác trong trích xuất tư thế học sinh. Zhu và cộng sự [8] đề xuất mạng Joint Cross-Attention Fusion Network, tích hợp dữ liệu ánh nhìn và chuyển động chuột nhằm theo dõi mức độ tương tác của học sinh trong môi trường học trực tuyến. Nghiên cứu [9] phát triển phương pháp STrack4Re, định hình bài toán nhận diện hành vi dưới dạng bài toán theo dõi đa đối tượng (Multi-Object Tracking), sử dụng YOLOv5 và OC-SORT để đảm bảo độ chính xác cao ngay cả trong điều kiện bị che khuất. Ikawati và cộng sự [10] tiếp cận theo hướng phân tích dữ liệu hành vi học tập từ nền tảng Moodle kết hợp bảng câu hỏi ILS (Index Learning Style), qua đó ứng dụng các mô hình kết hợp (Ensemble) như Bagging và Gradient Boosted Trees để dự đoán phong cách học tập của học sinh. Chen và cộng sự [11] cải tiến YOLOv8 bằng cách bổ sung các module như C2f_Res2block, cơ chế MHSA (Multi-Head Self-Attention) và EMA (Efficient Multi-Scale Attention), giúp mô hình nhận diện hiệu quả các hành vi nhỏ lẻ trong môi trường lớp học đông đúc. Fan và cộng sự [12] kết hợp YOLOv7 với Bi-level Routing Attention, đồng thời tích hợp thêm các thành phần như SlowFast, DeepSORT và YOLOv7-CrowdHuman, nhằm nâng cao hiệu suất nhận diện tám loại hành vi trong bộ dữ liệu SCB (Student Classroom Behavior). Ngoài ra, Lin và cộng sự [13] tập

trung vào hướng tối ưu hóa mô hình bằng cách xây dựng kiến trúc nhẹ dựa trên RT-DETR với backbone MobileNetV3, giúp giảm 90% số lượng tham số mà vẫn đảm bảo độ chính xác, đồng thời đề xuất cơ chế mã hóa vị trí có thể học (Learnable Position Encoding) và tăng mẫu động (Dynamic Upsampling) nhằm cải thiện nhận diện vật thể nhỏ trong lớp học.

Xuất phát từ nhu cầu thực tiễn và tiềm năng công nghệ, nghiên cứu này đề xuất và thực nghiệm trên hai hướng giải pháp sử dụng đặc trưng điểm khớp để nhận diện hành vi học sinh. Hướng thứ nhất sử dụng YOLOv8-Pose [14] – một mô hình kết hợp giữa phát hiện đối tượng và ước lượng tư thế – có ưu điểm về tốc độ xử lý nhanh, phù hợp với các hệ thống yêu cầu thời gian thực. Hướng thứ hai kết hợp Faster R-CNN – một kiến trúc phát hiện đối tượng có độ chính xác cao – với HRNet để thu được các điểm khớp chất lượng cao và ổn định, đặc biệt trong các khung hình có nhiều đối tượng hoặc bị che khuất [15], [16]. Dữ liệu các điểm khớp thu được từ hai hướng này sẽ được đưa vào một mô hình CNN để phân loại hành vi học sinh thành các nhóm như: phát biểu, nhìn thẳng, cúi đầu và ngủ gục.

Mục tiêu của nghiên cứu là so sánh hiệu quả giữa hai đường ống (YOLOv8-Pose và Faster R-CNN + HRNet) trong bài toán nhận diện hành vi học sinh. Nghiên cứu đóng góp ba điểm chính: (i) Xây dựng bộ dữ liệu hành vi học sinh có gán nhãn trong môi trường thực; (ii) Thiết kế và đánh giá hai đường ống xử lý dựa trên các điểm khớp; và (iii) Cung cấp góc nhìn thực nghiệm về độ chính xác, góp phần định hướng phát triển các hệ thống giám sát lớp học thông minh trong tương lai.

2. Phương pháp áp dụng

2.1. Tổng quan về cấu trúc hệ thống

Trong nghiên cứu này, chúng tôi đề xuất một hệ thống nhận diện tư thế học sinh nhằm hỗ trợ giám sát hành vi học tập trong môi trường lớp học thông qua ảnh đầu vào. Hệ thống bao gồm ba giai đoạn chính: phát hiện đối tượng, trích xuất điểm khớp cơ thể, và phân loại tư thế (Hình 1). Tùy thuộc vào kiến trúc sử dụng, quá trình phát hiện và trích xuất điểm khớp cơ thể có thể được thực hiện theo hai hướng. Với phương pháp kết hợp Faster R-CNN và HRNet, đầu tiên hệ thống sử dụng Faster R-CNN để xác định vùng chứa đối tượng học sinh, sau đó áp dụng HRNet để trích xuất các điểm khớp quan trọng trên cơ thể như mắt, vai, khuỷu tay, cổ tay và lưng, v.v. Trong khi đó, nếu sử dụng YOLO-pose [15], quá trình phát hiện đối tượng và trích xuất điểm khớp được thực hiện đồng thời trong một mô hình duy nhất, giúp giảm thời gian xử lý và đơn giản hóa quy trình. Các tọa độ điểm khớp thu được sẽ được sử dụng làm đầu vào cho một mạng CNN được thiết kế chuyên biệt [16]. Mạng CNN này có vai trò học các đặc trưng hình học và mối quan hệ không gian giữa các điểm khớp, từ đó thực hiện phân loại hành vi tương ứng. Kết quả đầu ra của hệ thống là nhãn tư thế thể hiện hành vi học tập của học sinh như: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Hệ thống này được xây dựng với mục tiêu hỗ trợ giáo viên và nhà trường trong việc đánh giá thái độ học tập của học sinh một cách khách quan, tự động và hiệu quả.

2.2. Trích xuất điểm khớp cơ thể bằng mô hình HRNet

Trong hệ thống nhận diện hành vi học sinh, bước đầu tiên và có tính quyết định là phát hiện chính xác từng học sinh trong từng khung hình của video lớp học. Để thực hiện nhiệm vụ này chúng tôi đã đề xuất hai hướng tiếp cận chính, hướng tiếp cận đầu tiên chúng tôi sử dụng mô hình Faster R-CNN [1] đã được huấn luyện trước – một kiến trúc phát hiện đối tượng tiên tiến, kết hợp giữa mạng đề xuất vùng (Region Proposal Network – RPN) và mạng phân loại – nhằm xác định chính xác các vùng chứa đối tượng trong ảnh. Faster R-CNN đặc biệt phù hợp với môi trường lớp học thực tế, nơi các học sinh thường ngồi gần nhau với đa dạng tư thế, đồng thời có thể bị che khuất bởi các vật thể như bàn, ghế hoặc balô. Sau khi được xử lý bằng Faster R-CNN, mỗi khung hình sẽ cho ra tập các hộp giới hạn (Bounding Boxes) tương ứng với từng học sinh được nhận diện, qua đó xác định vị trí chính xác của từng học sinh (Student Instances) trong ảnh.

Các vùng chứa học sinh này sau đó được cắt từ khung hình gốc và sử dụng làm đầu vào cho bước tiếp theo: ước lượng tư thế cơ thể (Pose Estimation). Để thực hiện bước này, hệ thống của chúng tôi tích hợp mô hình HRNet [2] (High-Resolution Network) đã được huấn luyện trước – một trong những mô hình hiện đại và chính xác nhất trong lĩnh vực trích xuất điểm khớp cơ thể người (Human Pose Keypoints). Khác với các mô hình trước đó như OpenPose hay SimpleBaseline, HRNet có khả năng duy trì thông tin ở độ phân giải cao xuyên suốt toàn bộ kiến trúc mạng, giúp cải thiện đáng kể độ chính xác trong việc định vị các điểm khớp, ngay cả trong các điều kiện phức tạp như tư thế bị che khuất, ánh sáng yếu hoặc nhiễu hình ảnh trong lớp học.

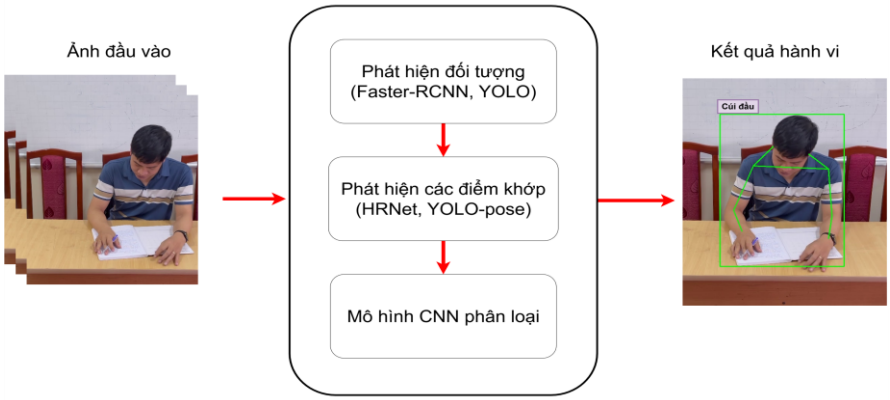

Hình 1. *Tổng quan về hệ thống*

Mặc dù HRNet có thể dự đoán lên đến 17 điểm khớp trên cơ thể, trong nghiên cứu này chúng tôi chọn lọc 10 điểm khớp chính bao gồm: hai tai, hai vai, hai khuỷu tay, hai cổ tay và hai hông – là những điểm có giá trị đặc trưng cao trong việc phân tích hành vi học tập như: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Các điểm khớp được trích xuất từ HRNet sẽ là cơ sở cho các bước phân tích hành vi học sinh trong lớp học ở giai đoạn sau. Hình 2 minh họa các điểm khớp được chúng tôi sử dụng.

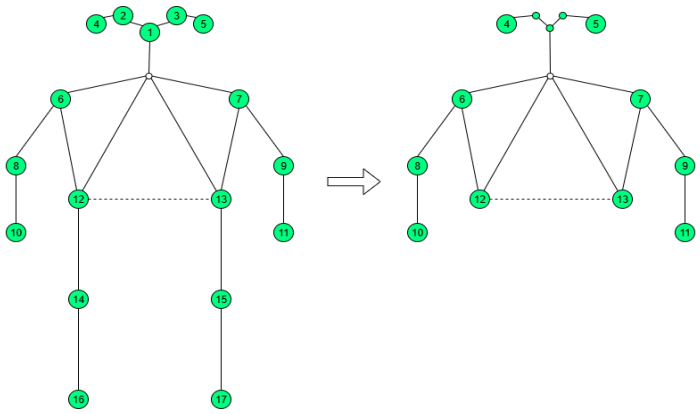

Hình 2. *Các điểm khớp được lựa chọn*

2.3. Trích xuất điểm khớp cơ thể bằng mô hình YOLOv8-pose

Hướng tiếp cận thứ hai trong hệ thống nhận diện hành vi học sinh của chúng tôi là sử dụng mô hình YOLOv8-Pose [14] – một phiên bản mở rộng của kiến trúc phát hiện đối tượng YOLOv8 được tối ưu hóa để thực hiện đồng thời cả hai nhiệm vụ: phát hiện đối tượng (Object Detection) và ước lượng các điểm khớp cơ thể (Pose Estimation). Không giống như cách tiếp trên cận phân tách hai bước như khi sử dụng Faster R-CNN và HRNet, YOLOv8-Pose cho phép hệ thống thực

hiện phát hiện học sinh và trích xuất các điểm khớp cơ thể trong cùng một bước, giúp giảm thời gian xử lý và độ phức tạp hệ thống, từ đó tăng hiệu suất trong các ứng dụng thời gian thực.

Trong nghiên cứu này, chúng tôi sử dụng YOLOv8-Pose được huấn luyện trước trên các tập dữ liệu tư thế người như COCO-Keypoints, và có khả năng nhận diện đồng thời các hộp giới hạn của học sinh trong khung hình, đồng thời dự đoán vị trí các điểm khớp quan trọng trên cơ thể mỗi học sinh. Mô hình này đặc biệt hữu ích trong môi trường lớp học, nơi nhiều học sinh có thể bị che khuất một phần hoặc thay đổi tư thế liên tục. Với cấu trúc mạng nhẹ, tốc độ xử lý nhanh và độ chính xác cao, YOLOv8-Pose cho phép hệ thống đạt được hiệu quả cả về mặt thời gian lẫn tài nguyên tính toán mà không làm giảm độ tin cậy của dữ liệu thu được.

Tương tự như hướng tiếp cận đầu tiên, mặc dù YOLOv8-Pose có khả năng dự đoán toàn bộ 17 điểm khớp trên cơ thể, trong nghiên cứu của chúng tôi chỉ lựa chọn 10 điểm khớp chính, bao gồm: hai tai, hai vai, hai khuỷu tay, hai cổ tay và hai hông – là những điểm có tính biểu đạt cao trong phân tích hành vi học sinh. Tập hợp các điểm khớp trên cơ thể này được sử dụng làm đầu vào cho các mô-đun phân loại hành vi ở giai đoạn sau, giúp hệ thống đánh giá mức độ tập trung, sự hợp tác hoặc biểu hiện chán nản của từng học sinh một cách hiệu quả và liên tục trong lớp học. Hình 2 minh họa các điểm khớp được sử dụng trong hướng tiếp cận này.

2.4. Phân loại tư thế bằng mô hình CNN

Sau khi các điểm khớp cơ thể của học sinh được trích xuất thành công từ khung hình thông qua một trong hai hướng tiếp cận ở giai đoạn trước, hệ thống tiến hành bước tiếp theo là phân loại tư thế học sinh nhằm nhận diện các hành vi học tập cụ thể như: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Để thực hiện nhiệm vụ này, chúng tôi xây dựng một mô hình mạng CNN với kiến trúc được thiết kế riêng, tối ưu cho các điểm khớp cơ thể làm đầu vào.

Cụ thể, mỗi học sinh trong một khung hình sẽ có một tập các điểm khớp gồm các điểm khớp quan trọng (hai tai, hai vai, hai khuỷu tay, hai cổ tay và hai hông). Mỗi điểm khớp được biểu diễn dưới dạng tọa độ (x,y), do đó một mẫu đầu vào cho mạng CNN sẽ là một vector kích thước (2x10), tương đương với ma trận (2x10) đại diện cho đặc trưng không gian của tư thế. Trước khi đưa vào mô hình, các tọa độ này được chuẩn hóa về khoảng [0, 1] theo kích thước của hộp giới hạn tương ứng, nhằm tăng tính ổn định khi huấn luyện.

Kiến trúc của mô hình CNN tự định nghĩa bao gồm hai khối tích chập (convolutional blocks), mỗi khối bao gồm một lớp tích chập (Conv1D), một hàm kích hoạt ReLU và một lớp chuẩn hóa theo lô (BatchNorm 1D). Sau các khối tích chập, đầu ra được làm phẳng (Flatten) và đi qua một lớp fully connected (Dense) để học các biểu diễn phi tuyến cho bài toán phân loại. Lớp cuối cùng sử dụng hàm softmax để suy ra xác suất thuộc về từng lớp hành vi. Kiến trúc CNN được chúng tôi định nghĩa được mô tả trong Hình 3.

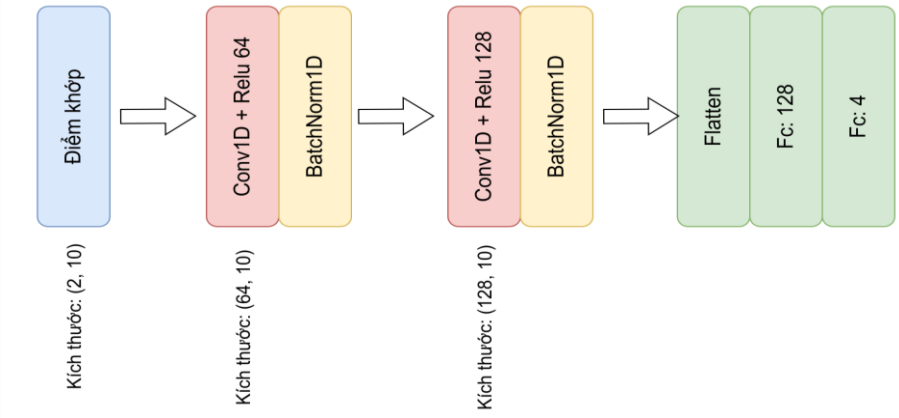

Hình 3. *Kiến trúc CNN phân loại các hành vi của học sinh*

3. Kết quả thực nghiệm

3.1. Thiết bị thực nghiệm

Thiết bị phần cứng và framework: Để triển khai hiệu quả các mô hình học sâu, chúng tôi sử dụng framework Pytorch – một trong những thư viện hàng đầu được phát triển dành cho các ứng dụng học sâu. Pytorch cung cấp một bộ công cụ toàn diện và các chức năng cần thiết cho việc thiết kế, huấn luyện và triển khai các kiến trúc mạng nơ-ron. Trong nghiên cứu này, quá trình huấn luyện mô hình được thực hiện trên một máy chủ chuyên dụng với cấu hình phần cứng như sau:

CPU: CPU 11th Gen Intel© Core™ i5-11400H @ 2.70GHz × 6

GPU: GPU GeForce RTX 3050 Ti Mobile

RAM: 4 GB

Quá trình huấn luyện được thực hiện trong 50 epoch với tốc độ học (Learning Rate) là 0,0001. Các mô hình tốt nhất được lưu lại dưới dạng bản lưu mô hình (Checkpoint) dựa trên độ mất mát trên tập xác thực, nhằm đảm bảo giữ lại mô hình có hiệu suất tốt nhất.

Cơ sở dữ liệu: Trong nghiên cứu này, hệ thống được thiết kế với mục tiêu chính là phân loại hành vi của học sinh trong lớp học, trong khi nhiệm vụ ước tính tư thế được xử lý bởi các mô hình được đào tạo trước, như chúng tôi đã mô tả trong Phần 2.

Thiết kế mô-đun này cho phép đường ống thu thập và xử lý dữ liệu tập trung hoàn toàn vào nhiệm vụ phân loại hành vi, mà không cần phải đào tạo lại toàn bộ đường ống từ đầu. Cụ thể, các đặc điểm điểm khớp được trích xuất bằng mô hình HRNet hoặc YOLOv8-pose và sau đó đưa vào mạng CNN được xây dựng riêng để phân loại hành vi của học sinh thành bốn loại chính: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Tận dụng các mô hình được đào tạo trước không chỉ giúp giảm đáng kể chi phí gán nhãn dữ liệu thủ công mà còn cho phép tập trung nguồn lực vào việc tối ưu hóa thành phần phân loại hành vi của hệ thống. Bộ dữ liệu được thu thập độc lập bằng cách chụp ảnh học sinh trong môi trường lớp học thực tế. Thống kê chi tiết về số lượng hình ảnh thu thập được cho từng lớp hành vi được trình bày trong Bảng 1.

Bảng 1. *Chi tiết về dữ liệu*

Hành vi	Tập huấn luyện	Tập xác thực	Tập kiểm thử
Phát biểu	1470	210	420
Nhìn thẳng	1470	210	420
Cúi đầu	1433	207	410
Ngủ gục	1470	210	420
Tổng số	**5843**	**837**	**1670**

3.2. Kết quả huấn luyện mô hình

Hình 4 cho thấy quá trình huấn luyện hai mô hình sử dụng các điểm khớp từ YOLOv8-pose và HRNet được theo dõi và đánh giá thông qua các chỉ số về hàm mất mát và độ chính xác trên cả tập huấn luyện và tập xác thực trong 50 epoch. Nhìn chung, cả hai mô hình đều cho thấy khả năng hội tụ tốt với xu hướng giảm ổn định của hàm mất mát và sự gia tăng rõ rệt của độ chính xác theo thời gian huấn luyện. Tuy nhiên, mô hình sử dụng các điểm khớp từ HRNet thể hiện hiệu quả vượt trội hơn so với YOLOv8-pose ở cả bốn khía cạnh: giá trị mất mát trên tập huấn luyện (training loss), độ chính xác trên tập huấn luyện (training accuracy), giá trị mất mát trên tập xác thực (validation loss), độ chính xác trên tập xác thực (validation accuracy).

Cụ thể, CNN sử dụng các điểm khớp của HRNet đạt tốc độ hội tụ nhanh hơn rõ rệt với giá trị lỗi giảm mạnh chỉ sau 10 epoch đầu tiên, trong khi đó CNN sử dụng các điểm khớp của YOLOv8-pose cần nhiều epoch hơn để đạt được mức giảm tương đương. Ở biểu đồ giá trị mất mát trên tập huấn luyện, CNN với các điểm khớp của HRNet bắt đầu với giá trị thấp hơn và giảm nhanh hơn so với sử dụng các điểm khớp của YOLOv8-pose, chứng tỏ mô hình này học được đặc trưng tốt hơn từ đầu vào. Đồng thời, biểu đồ độ chính xác trên tập huấn luyện cho thấy CNN sử

dụng các điểm khớp của HRNet đạt trên 0,90 độ chính xác chỉ sau khoảng 10 epoch đầu, trong khi sử dụng các điểm khớp của YOLOv8-pose cần gần 20 epoch mới tiệm cận được mức này.

Đối với tập xác thực, giá trị mất mát trên tập xác thực của mô hình sử dụng các điểm khớp từ HRNet cũng giảm nhanh và ổn định, đồng thời duy trì ở mức thấp hơn so với YOLOv8-pose trong toàn bộ quá trình huấn luyện. Đặc biệt, mô hình sử dụng các điểm khớp từ HRNet đạt độ chính xác xác thực trên 0,95 rất sớm và giữ ổn định ở mức gần 0,99 trong các epoch sau, trong khi YOLOv8-pose mặc dù cũng đạt hiệu suất cao nhưng mất nhiều thời gian hơn để vượt mốc 0,95 và chỉ tiệm cận ngưỡng 0,98 vào cuối quá trình huấn luyện.

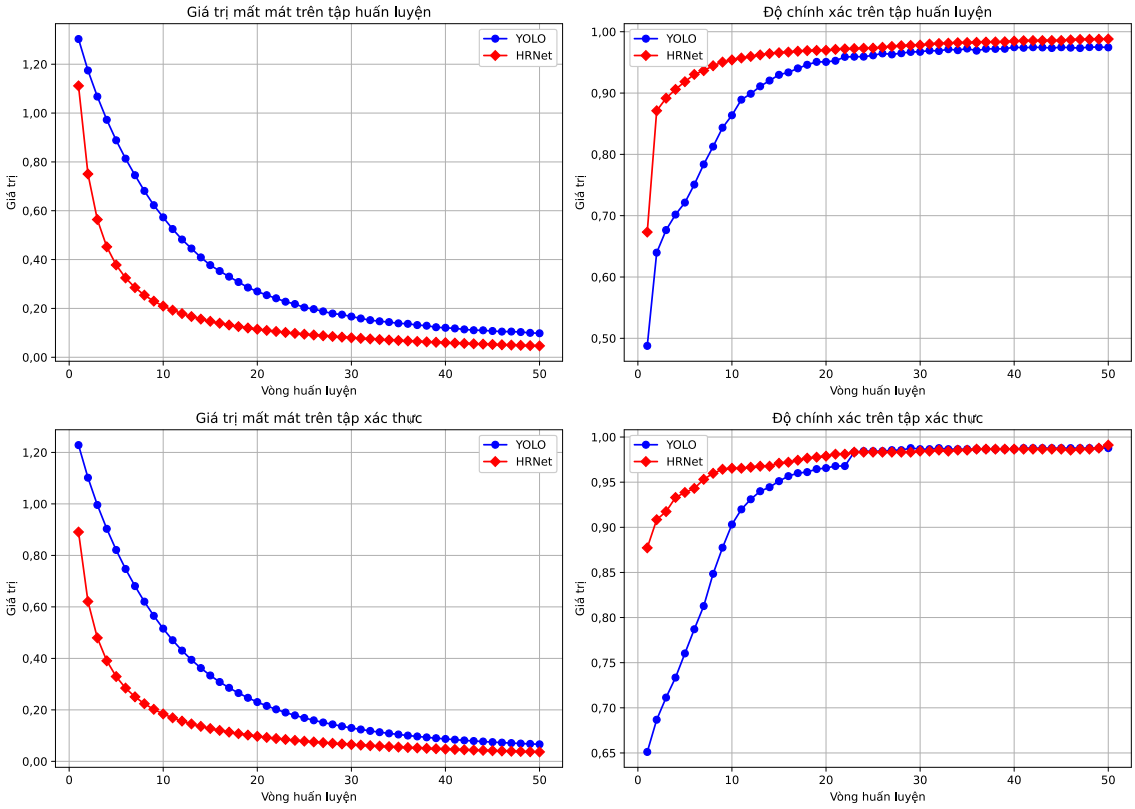

Hình 4. *Kết quả quá trình huấn luyện*

Những kết quả này cho thấy rằng việc sử dụng các điểm khớp từ HRNet cung cấp thông tin không gian chi tiết và ổn định hơn, giúp mạng phân loại CNN học được các biểu diễn hình học hiệu quả hơn, từ đó cải thiện độ chính xác tổng thể. Mô hình không chỉ học nhanh hơn mà còn cho thấy độ tổng quát tốt hơn trên tập xác thực, khẳng định ưu thế của phương pháp này trong các bài toán phân loại tư thế học sinh dựa trên dữ liệu các điểm khớp của cơ thể.

Kết quả phân loại hành vi trên tập kiểm thử sử dụng các điểm khớp HRNet trên Hình 5 cho thấy hiệu suất tổng thể rất tốt. Biểu đồ ma trận nhầm lẫn (Confusion matrix) cho thấy mô hình có khả năng phân biệt các hành vi một cách chính xác, với số lượng dự đoán đúng cao trên đường chéo chính. Số lượng nhầm lẫn giữa các lớp là rất nhỏ, trong đó hành vi "nhìn thẳng" và "cúi đầu" có một vài trường hợp bị nhầm lẫn với nhau, có thể do đặc trưng tư thế tương đối giống nhau ở một số khung hình.

Biểu đồ độ chính xác (precision) và độ phủ (recall) đều phản ánh độ chính xác và độ bao phủ rất cao, dao động trong khoảng từ 0,96 đến hơn 0,99 cho hầu hết các lớp. Đặc biệt, lớp hành vi "ngủ gục" có độ chính xác cao nhất (0,9926), cho thấy rất ít trường hợp bị nhầm lẫn với lớp khác. Lớp hành vi "nhìn thẳng" và "cúi đầu" có độ phủ là 0,9738, chứng minh mô hình nhận diện tốt nhưng vẫn có vài trường hợp bị bỏ sót.

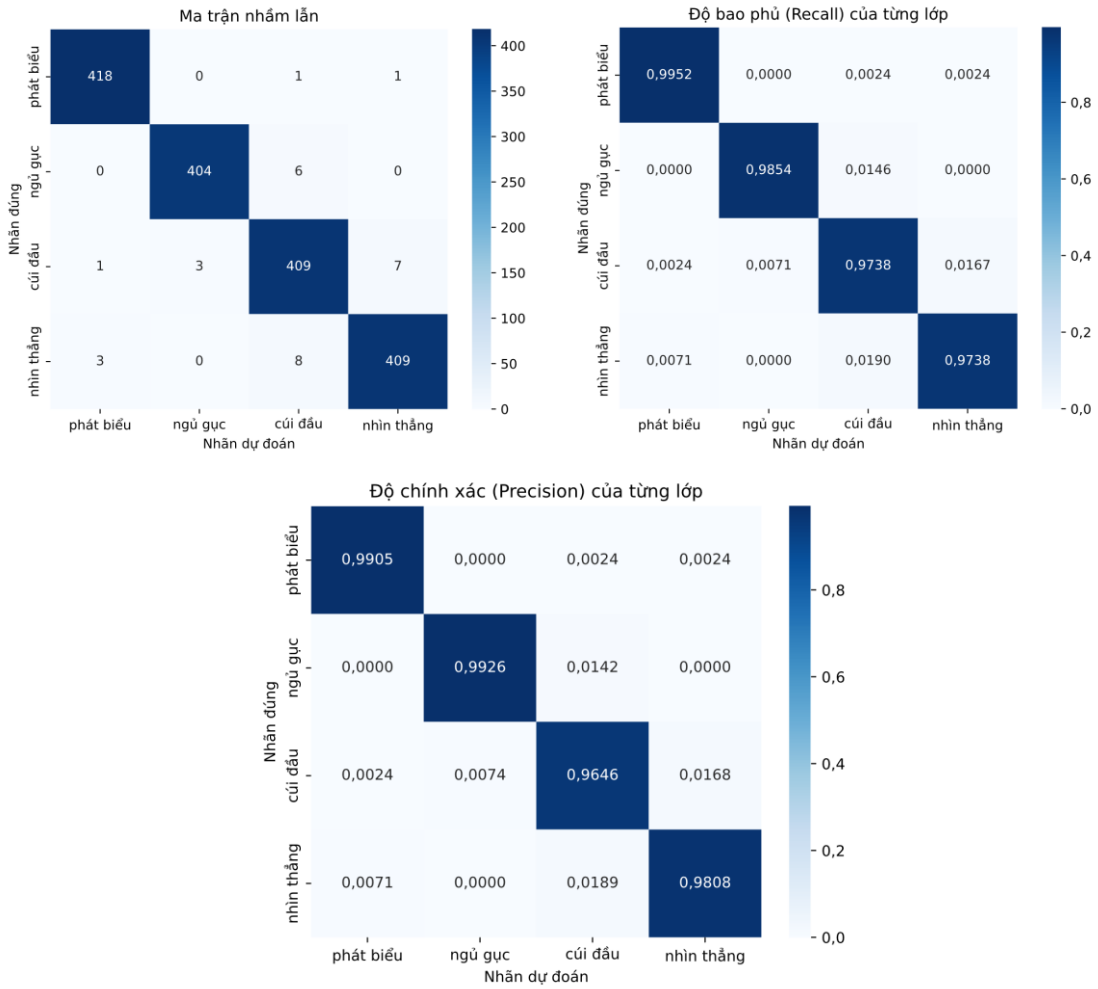

Hình 5. *Kết quả đánh giá phân loại hành vi trên tập kiểm tra sử dụng các điểm khớp của HRNet*

Hình 6 cho thấy kết quả phân loại hành vi trên tập kiểm thử sử dụng các điểm khớp từ mô hình YOLOv8-Pose thể hiện hiệu suất tốt và ổn định, tuy có một số điểm cần lưu ý so với HRNet. Dựa vào biểu đồ ma trận nhầm lẫn (Confusion matrix), mô hình phân loại tương đối chính xác các hành vi, với phần lớn dự đoán đúng nằm trên đường chéo chính. Tuy nhiên, hành vi "nhìn thẳng" có xu hướng bị nhầm lẫn với hành vi "phát biểu" nhiều hơn, chủ yếu do đặc trưng tư thế giữa hai hành vi này có sự chồng chéo đáng kể, đặc biệt khi cánh tay không rõ ràng hoặc bị che khuất, cũng như khi học sinh ở vị trí xa làm giảm chi tiết hình ảnh.

Xét theo biểu đồ độ chính xác (precision) và độ phủ (recall), ta nhận thấy rằng các chỉ số cho lớp hành vi "phát biểu" và "nhìn thẳng" thấp hơn một chút so với các lớp khác. Độ chính xác của lớp hành vi "phát biểu" là 0,9698, trong khi độ phủ là 0,9952 – cho thấy mô hình nhận diện đúng phần lớn hành vi này, nhưng vẫn bị một số nhãn khác nhầm lẫn với hành vi "phát biểu". Tương tự, lớp hành vi "nhìn thẳng" có độ phủ là 0,9571 – mức thấp nhất trong bốn lớp, chủ yếu do nhầm sang hành vi "phát biểu".

Mặc dù vậy, các lớp hành vi còn lại như "ngủ gục" và "cúi đầu" vẫn duy trì độ chính xác cao với độ chính xác và độ phủ đều trên 0,97. Điều này cho thấy mô hình sử dụng các điểm khớp từ YOLOv8-Pose vẫn có khả năng học tốt các đặc trưng cử chỉ khi được cung cấp đầy đủ các điểm khớp, nhưng có thể bị ảnh hưởng bởi độ chính xác định vị điểm khớp thấp hơn so với HRNet.

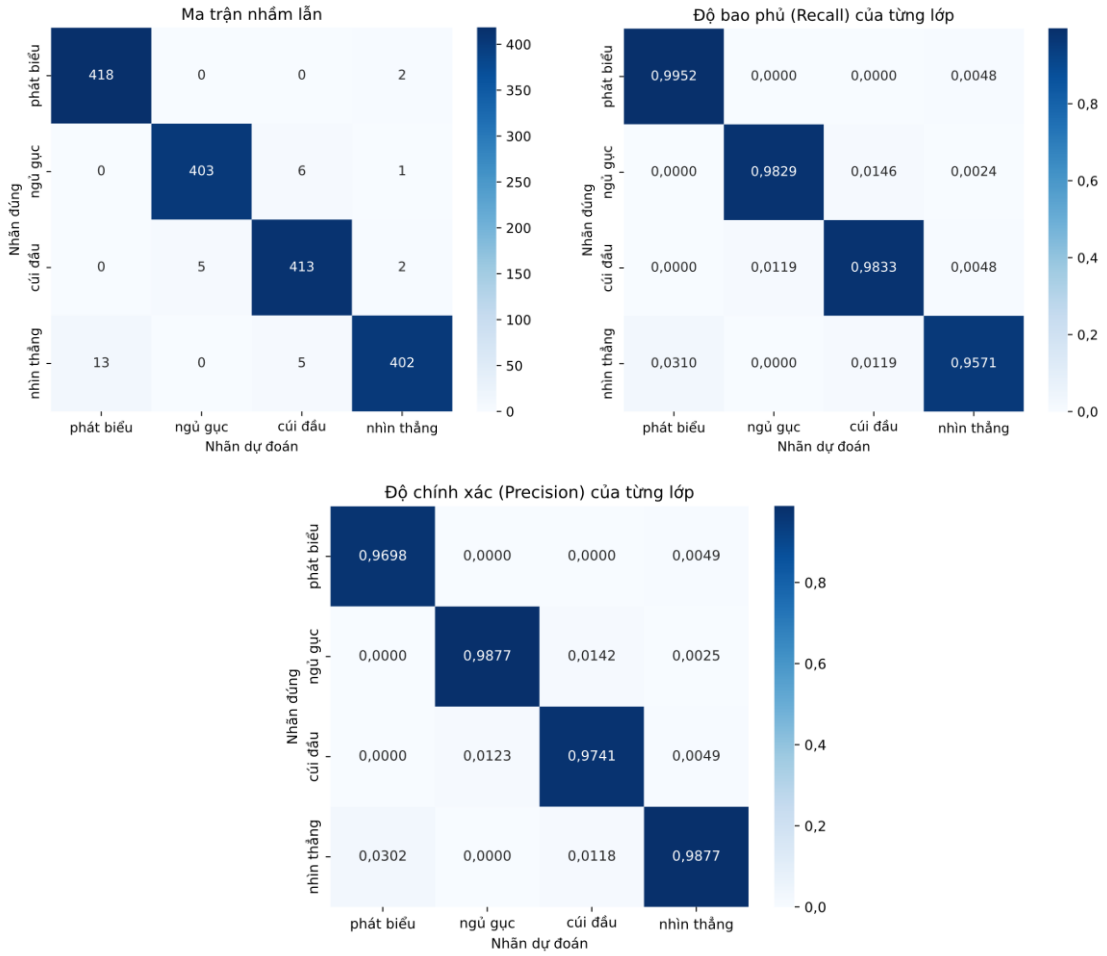

Hình 6. *Kết quả đánh giá phân loại hành vi trên tập kiểm tra sử dụng các điểm khớp của YOLOv8-pose*

3.3. Đánh giá kết quả thực nghiệm

Hình 7 và Hình 8 trình bày kết quả kiểm thử hệ thống nhận diện hành vi học sinh trong bối cảnh lớp học thực tế, nhằm đánh giá tính hiệu quả, độ chính xác cũng như khả năng ứng dụng của hệ thống trong các môi trường giáo dục hiện hành. Các hình minh họa trực quan này đóng vai trò như bằng chứng thực nghiệm cho thấy hệ thống có thể vận hành ổn định và thích ứng tốt với điều kiện triển khai ngoài thực tế, vượt ra khỏi các mô phỏng trong môi trường phòng thí nghiệm.

Trong Hình 7, hệ thống được kiểm tra trong tình huống đơn giản với chỉ một học sinh có mặt trong khung hình. Qua đó, hệ thống đã nhận diện chính xác và gán nhãn bốn hành vi phổ biến thường gặp trong lớp học bao gồm: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Các điểm khớp cơ thể của học sinh được trích xuất với độ chính xác cao thông qua mô hình HRNet hoặc YOLOv8-pose. Những đặc trưng không gian này được hệ thống sử dụng để phân tích tư thế tổng thể của học sinh, từ đó đưa ra quyết định phân loại hành vi. Trường hợp đơn đối tượng này đóng vai trò như một bước xác minh quan trọng trong toàn bộ quy trình phân tích, đảm bảo rằng hệ thống có khả năng phát hiện và phân loại hành vi chính xác ở cấp độ từng cá nhân ngay cả khi thiếu đi các ngữ cảnh hỗ trợ từ những đối tượng xung quanh.

Hình 8 mở rộng quá trình thử nghiệm sang một môi trường lớp học thực tế với mật độ học sinh cao – một tình huống đặc trưng trong các lớp phổ thông hiện nay. Trong bối cảnh phức tạp với nhiều cá thể cùng xuất hiện trong khung hình, hệ thống vẫn duy trì được hiệu suất ổn định và chính xác. Cụ thể, gần như toàn bộ học sinh trong lớp đều được hệ thống phát hiện và gán nhãn

hành vi một cách rõ ràng, theo bốn nhóm hành vi đã định nghĩa trước: phát biểu, nhìn thẳng, cúi đầu và ngủ gục. Mỗi cá nhân được xác định bằng hộp giới hạn đi kèm nhãn hành vi tương ứng, giúp trực quan hóa kết quả và hỗ trợ quá trình kiểm chứng một cách thuận tiện.

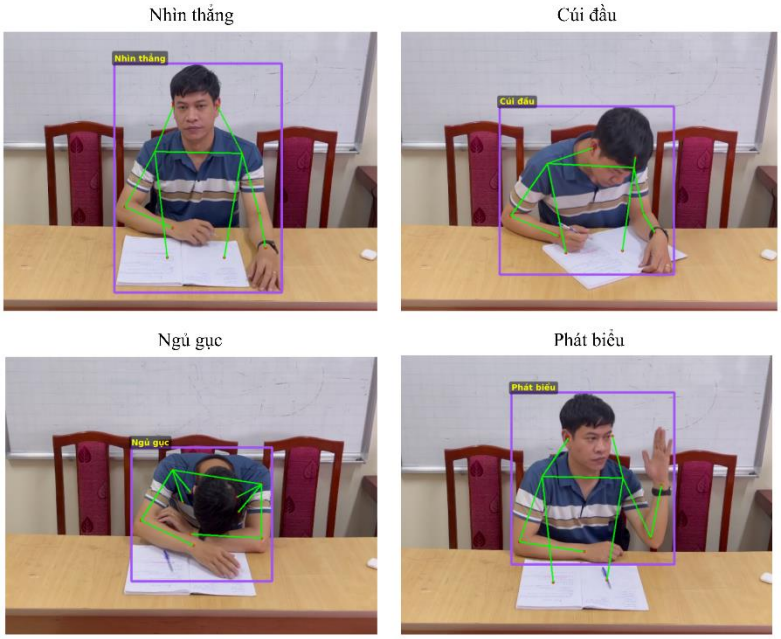

Hình 7. *Phân loại hành vi trong môi trường đối tượng đơn lẻ*

Hình 8.a thể hiện kết quả từ quy trình xử lý sử dụng Faster R-CNN cho nhiệm vụ phát hiện đối tượng và HRNet cho trích xuất điểm khớp. Hình 8.b sử dụng quy trình xử lý với YOLOv8-Pose, một mô hình gộp chung hai bước phát hiện và trích xuất điểm khớp. Hình 8.c trích xuất các vùng ảnh chứa học sinh từ hình tổng thể, hiển thị riêng biệt từng cá nhân cùng khung xương và nhãn hành vi tương ứng. Việc trực quan hóa này hỗ trợ đánh giá định tính mức độ chính xác của hệ thống trong từng trường hợp cụ thể. Những quan sát trên cho thấy hệ thống hoạt động hiệu quả trong việc nhận diện tư thế và phân loại hành vi của từng học sinh.

Tuy nhiên, do hệ thống sử dụng mô hình Faster R-CNN, YOLOv8-pose đã được huấn luyện sẵn (pre-trained model) cho bước phát hiện đối tượng nên vẫn tồn tại một số hạn chế. Cụ thể, các học sinh ở vị trí xa hoặc có kích thước hiển thị nhỏ trong ảnh có thể không được phát hiện đầy đủ, kéo theo việc hệ thống không thể tiến hành phân tích hành vi cho những cá thể đó. Đây là một hướng cải tiến quan trọng trong các bước phát triển tiếp theo nhằm nâng cao độ bao phủ và tính toàn vẹn của hệ thống trong các môi trường lớp học đông đúc.

Kết quả đánh giá cũng cho thấy thời gian xử lý trung bình của mô hình Faster R-CNN và HRNet là 840 ms/ảnh, trong khi mô hình YOLOv8-Pose chỉ mất 30 ms/ảnh, cho thấy YOLOv8-Pose có ưu thế vượt trội về tốc độ xử lý và dễ dàng triển khai trong các hệ thống giám sát thời gian thực. Những kết quả thu được từ các tình huống trên cho thấy hệ thống không chỉ có khả năng hoạt động chính xác trong môi trường đơn giản mà còn có thể mở rộng hiệu quả sang các môi trường đa đối tượng với sự thay đổi về tư thế, góc nhìn, và điều kiện ánh sáng. Khả năng cung cấp thông tin hành vi chi tiết theo từng cá nhân giúp hệ thống trở thành một công cụ hữu ích trong việc theo dõi mức độ tập trung, sự tương tác và thái độ học tập của học sinh trong lớp học. Từ đó, giáo viên hoặc người quản lý có thể đưa ra các quyết định sư phạm phù hợp và kịp thời nhằm nâng cao chất lượng dạy và học.

Tóm lại, các kết quả minh họa trong Hình 7 và Hình 8 đã chứng minh tính khả thi, hiệu quả và tiềm năng ứng dụng rộng rãi của hệ thống trong thực tế, đặc biệt là trong các mô hình lớp học thông minh, nơi việc giám sát hành vi học sinh theo thời gian thực là một yêu cầu thiết yếu.

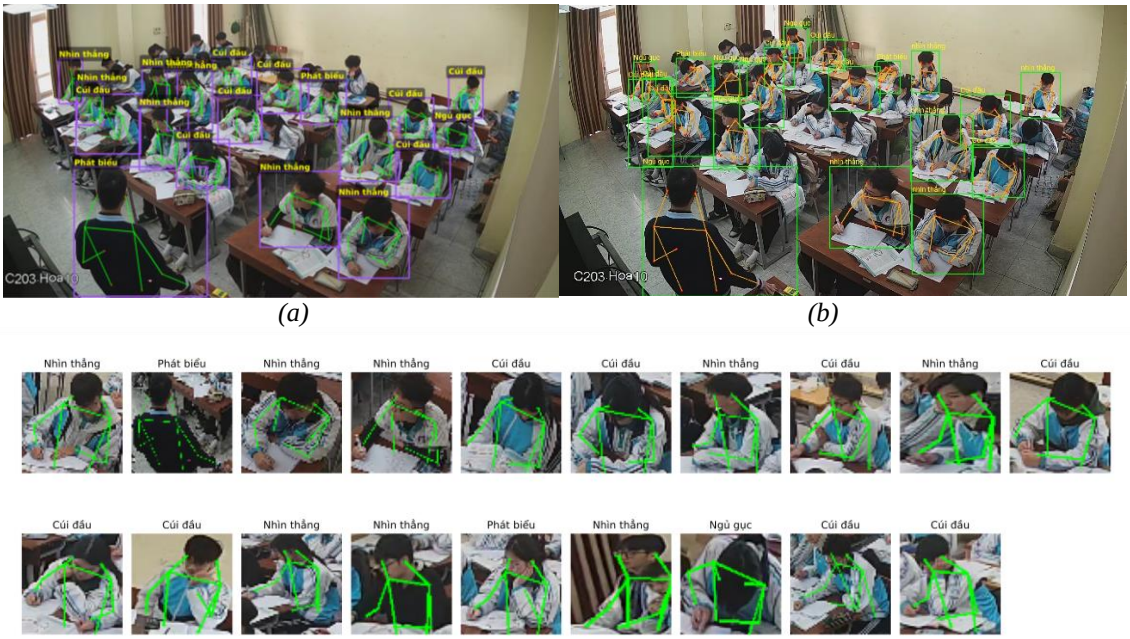

(a) *(b)*

(c)

Hình 8. *Phân loại hành vi trong môi trường nhiều đối tượng: (a) Phát hiện hành vi bằng YOLOv8-Pose, (b) Phát hiện hành vi bằng HRNet, (c) Hành vi của từng sinh viên*

4. Kết luận

Trong nghiên cứu này, chúng tôi đã đề xuất và đánh giá một hệ thống nhận diện tư thế học sinh trong môi trường lớp học dựa trên phương pháp học sâu, sử dụng thông tin các điểm khớp trích xuất từ hai mô hình hiện đại là HRNet và YOLOv8-Pose. Hệ thống được thiết kế nhằm phân loại các tư thế phổ biến như: phát biểu, nhìn thẳng, cúi đầu và ngủ gục, phục vụ cho mục tiêu phân tích hành vi học tập và hỗ trợ giảng dạy thông minh.

Kết quả thực nghiệm cho thấy cả hai phương pháp đều có khả năng hỗ trợ hiệu quả cho bài toán nhận diện tư thế, tuy nhiên mức độ chính xác và ổn định của hệ thống phụ thuộc đáng kể vào chất lượng các điểm khớp đầu vào. Mô hình sử dụng các điểm khớp của HRNet đạt hiệu suất cao hơn đáng kể so với YOLOv8-Pose, với độ chính xác và độ bao phủ trên từng lớp hành vi đều vượt ngưỡng 0,96, trong khi mô hình sử dụng các điểm khớp từ YOLOv8-Pose có độ chính xác thấp hơn ở các hành vi dễ gây nhầm lẫn như hành vi "phát biểu" và "nhìn thẳng". Sự khác biệt này xuất phát từ khả năng biểu diễn không gian vượt trội của HRNet, nhờ kiến trúc giữ nguyên độ phân giải trong quá trình truyền đặc trưng, giúp mô hình phân biệt tốt hơn các tư thế có hình thái tương đồng.

Mặc dù YOLOv8-Pose có ưu điểm về tốc độ xử lý và dễ triển khai trong các hệ thống thời gian thực, HRNet lại tỏ ra phù hợp hơn trong các ứng dụng đòi hỏi độ chính xác cao như giám sát học sinh, đánh giá mức độ tương tác trong lớp học hoặc phát hiện hành vi bất thường. Từ đó, có thể kết luận rằng việc lựa chọn mô hình trích xuất các điểm khớp là yếu tố then chốt ảnh hưởng đến toàn bộ hiệu quả hệ thống nhận diện tư thế. Hệ thống vẫn tồn tại hạn chế trong việc phát hiện học sinh ở vị trí xa hoặc có kích thước nhỏ trong ảnh, song mức ảnh hưởng chưa đáng kể đến kết quả chung. Đây là một điểm yếu cần được cải thiện trong các nghiên cứu tiếp theo, chẳng hạn như áp dụng mô hình đa tỉ lệ, tăng cường ảnh hoặc sử dụng camera có độ phân giải cao hơn để cải thiện khả năng nhận diện.

Lời cảm ơn

Nghiên cứu này được hỗ trợ bởi đề tài khoa học và công nghệ cấp tỉnh thực hiện từ năm 2023 với mã số ĐT/KTCN/18/2023.

TÀI LIỆU THAM KHẢO/ REFERENCES

[1] H. Jiang and E. Learned-Miller, "Face Detection with the Faster R-CNN," in *Proc. 12th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2017)*, Washington, DC, USA, 2017, pp. 650–657.

[2] K. Sun, B. Xiao, D. Liu, and J. Wang, "Deep High-Resolution Representation Learning for Human Pose Estimation," *Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 2019, pp. 5693–5703.

[3] A. A. Abdelrahman, T. Hempel, A. Khalifa, and A. Al-Hamadi, "L2CS-Net: Fine-Grained Gaze Estimation in Unconstrained Environments," in *Proc. 8th International Conference on Frontiers of Signal Processing (ICFSP)*, Corfu, Greece, 2023, pp. 1–5.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, Nevada, USA, 2016, pp. 770–778.

[5] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," in *Proc. Computer Vision and Pattern Recognition*, Honolulu, Hawaii, 2017, pp. 4700–4708.

[6] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," *arXiv:1704.04861*, pp. 1–9, 2017.

[7] Q. Jia and J. He, "Student Behavior Recognition in Classroom Based on Deep Learning," *Applied Sciences*, vol. 14, no. 17, 2024, Art. no. 7981.

[8] R. Zhu, L. Shi, Y. Song, and Z. Cai, "Integrating Gaze and Mouse Via Joint Cross-Attention Fusion Net for Students' Activity Recognition in E-learning," in *Proc. The ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, New York, NY, USA, vol. 7, 2023, pp. 1–35.

[9] P.-D. Nguyen, N.-T. Le, K.-H. Bui, H.-Q. Nguyen, H.-Q. Nguyen, and T.-L. Le, "A Method for Continuous Student Activity Recognition from Classroom Videos," *International Journal of Machine Learning and Cybernetics*, vol. 16, pp. 1–25, 2025.

[10] Y. Ikawati, M. U. H. A. Rasyid, and I. Winarno, "Student Behavior Analysis to Predict Learning Styles Based Felder Silverman Model Using Ensemble Tree Method," *EMITTER International Journal of Engineering Technology*, vol. 9, no. 1, pp. 92–106, 2021.

[11] H. Chen, G. Zhou, and H. Jiang, "Student Behavior Detection in the Classroom Based on Improved YOLOv8," *Sensors*, vol. 23, no. 20, pp. 1–18, 2023.

[12] Y. Fan, W. Tao, and W. Xiaofei, "Student Classroom Behavior Detection Based on YOLOv7+BRA and Multi-model Fusion," in *Proc. International Conference on Image and Graphics*, Nanjing, China, 2023, pp. 41–52.

[13] L. Lin, H. Yang, Q. Xu, Y. Xue, and D. Li, "Research on Student Classroom Behavior Detection Based on the Real-Time Detection Transformer Algorithm," *Applied Sciences*, vol. 14, no. 14, pp. 1–15, 2024.

[14] Ultralytics, "YOLOv8 Pose Models," April, 2023. [Online]. Available: https://github.com/ultralytics/ultralytics/issues/1915. [Accessed May 19, 2025].

[15] Ultralytics, "Pose Estimation," April, 2023. [Online]. Available: https://docs.ultralytics.com/tasks/pose. [Accessed May 19, 2025].

[16] T. Guo, J. Dong, H. Li, and Y. Gao, "Simple Convolutional Neural Network on Image Classification," in *Proc. 2nd International Conference on Big Data Analysis (ICBDA)*, Beijing, China, 2017, pp. 721–724.